Dédale

Fiche de défense pour le jury

Secure Horizons
Track 2
10–11 octobre 2026

Deux chemins, une décision humaine.
Le salarié s'apprête à faire un geste risqué. L'agent IA prend une instruction hostile pour une consigne. Dédale remonte les faits au même SOC. La preuve technique du Track 2 est l'appel d'outil de l'agent retenu par la passerelle après lecture d'un mail piégé.

Démo à montrer

1. **Salarié.** Camille ouvre un faux mail. Le garde du poste *simulé* avertit avant le clic. « Annuler » évite le geste ; « continuer » ouvre un incident. Le SOC ne coupe pas le poste.
2. **Agent.** Un agent *scripté* lit une instruction cachée et tente un appel d'outil. La passerelle le retient. Le SOC voit la source, l'instruction, l'outil et les droits. « Couper » révoque le jeton ; « reprendre » libère l'appel retenu.
3. **Preuve commune.** La console montre la chaîne, l'état final et l'auteur de la décision. ECS et Sigma exportent les faits. Le document NIS2 reste un brouillon à qualifier, jamais envoyé automatiquement.

Ce qui existe, ce qui reste à faire

Prototype : gestes salariés simulés, agent et outils locaux, passerelle, décisions SOC, boîte noire, backend local, exports. Le rapport de la démo est fictif et reste local.

Cible : capteur de poste autorisé, connexions messagerie et agents déployés, identités, rétention, essais sur données indépendantes. Aucune surveillance native du Mac ni connexion Outlook/Gmail n'est démontrée.

État des preuves

Au 10 octobre : **145 tests réussis** (backend 44, interne 31, poste 17, leurres 19, attaque 16, scripts de démo 18). La console passe `npm run build`. Ce bilan vérifie le prototype ; il ne mesure pas la détection en production. Aucun taux tiré du banc synthétique n'est avancé comme performance produit.

Cinq objections à traiter sans détour

« Encore une campagne de phishing ? »
La scène salarié intervient au moment du geste. La scène agent démontre la retenue d'un appel d'outil. Les deux remontent dans le même dossier SOC.

« L'agent a vraiment été piraté ? »
Le contenu hostile et la passerelle sont exécutés localement. Son cerveau est scripté pour une démo reproductible. Aucun taux de réussite sur des modèles réels n'est revendiqué.

« Pourquoi permettre "reprendre" ? »
L'analyste tranche après lecture de la chaîne. Reprendre libère l'appel retenu dans ce scénario ; une opération hors droits reste bloquée. Couper arrête la session et révoque le jeton.

« Y a-t-il eu une fuite ? »
Après « couper », aucun rapport ne part. Après « reprendre », seul un rapport fictif est écrit localement. Les textes distinguent tentative, blocage et exécution.

« Êtes-vous conformes à NIS2, OWASP ou MITRE ? »
Non. NIS2 est un brouillon à relire, sans qualification ni envoi automatique. OWASP Agentic, ATLAS et ATT&CK sont des repères techniques, pas des certifications.

Phrase de clôture. « Nous montrons ce que la passerelle a retenu, ce que l'humain a décidé et ce qui s'est réellement passé. Le reste est une cible de déploiement, pas une fonction déjà livrée. »

Source de cette fiche : `README.md`, `docs/DEMO.md`, `docs/PLAN_NILA_2026-10-10.md` et suites de tests du dépôt. Orbis Pay et ses données sont fictifs.